


MPECI 2025-2026

Desempenho de Servidores

Serviços baseado num único servidor

Recursos de um servidor:

- Capacidade de processamento: processador(es) + memória RAM
- Capacidade C da sua ligação à rede




Tipos de serviços

O desempenho de um servidor depende do tipo de serviço disponibilizado pelo servidor.

O tipo de serviço determina de que forma os recursos do servidor são usados e que recursos limitam o seu desempenho:


- serviços que requerem maioritariamente recursos de rede e, portanto, o seu desempenho é limitado pela capacidade C da ligação do servidor à rede
- serviços que requerem maioritariamente recursos de processamento e, portanto, o seu desempenho é limitado pela capacidade de processamento do servidor



Tipos de serviços


Neste módulo, vamos endereçar o desempenho de 3 tipos de serviços:

- serviços de *vídeo-streaming*, cujo desempenho está limitado pela capacidade C da ligação do servidor à rede
- serviços de dados, cujo desempenho está limitado pela capacidade de processamento do servidor
- serviços do tipo *Call Center*, cujo desempenho está limitado pelo número disponível de operadores



Serviços de *video-streaming*

- Serviços de *video-streaming* (por exemplo, Netflix, HBO Max, Disney+, etc.) providenciam aos seus utilizadores catálogos de filmes, séries e documentários
- O tempo de serviço de cada pedido é caracterizado pela duração do item pedido pelo utilizador
- Cada item requer um débito binário significativo durante a transmissão do item
- A capacidade C da ligação é mais limitativa do que a capacidade de processamento do servidor



Desempenho de um servidor de *video-streaming*

Se considerarmos que:

- a chegada de pedidos de filmes é um processo de Poisson com taxa λ
- a duração dos filmes é exponencialmente distribuída de média $1/\mu$
- os filmes são codificados num único formato cuja transmissão tem um débito binário B bps
- sendo a capacidade da ligação C bps, então a capacidade do servidor (em no. máximo de filmes que consegue transmitir em simultâneo) é $m = \lfloor C/B \rfloor$
- os pedidos são bloqueados (i.e., recusados) se o servidor estiver a transmitir m filmes (i.e., não existe fila de espera)


Então o servidor pode ser modelado por um sistema $M/M/m/m$

- o estado n ($n= 0,1,\dots, m$) representa o número de filmes em transmissão

Desempenho de um servidor de *video-streaming*

Num sistema $M/M/m/m$

- Processo de nascimento e morte:



- Probabilidade de cada estado:

$$\pi_n = \frac{\left(\frac{\lambda}{\mu}\right)^n / n!}{\sum_{i=0}^m \left(\left(\frac{\lambda}{\mu}\right)^i / i!\right)}, n = 0, 1, 2, \dots, m$$

- Probabilidade de bloqueio do serviço (fórmula de ErlangB):

$$\pi_m = \frac{\left(\frac{\lambda}{\mu}\right)^m / m!}{\sum_{i=0}^m \left(\left(\frac{\lambda}{\mu}\right)^i / i!\right)}$$

- No. médio de filmes em transmissão:

$$L = \sum_{n=0}^m (n \times \pi_n)$$

- Débito binário médio do servidor:

$$B_S = B \times L$$

Desempenho de um servidor de *video-streaming*

- No caso geral, os filmes são codificados em diferentes formatos, cada um providenciando uma qualidade audiovisual diferente e com um débito binário de transmissão diferente:
 - formatos com melhor qualidade audiovisual requerem maiores débitos binários de transmissão
- A cadeia de Markov que modela estes sistemas não é um processo de nascimento e morte simples:
 - cada estado necessita de identificar o número de filmes de cada formato que estão em transmissão
- No slide seguinte, esta situação é ilustrada no Exemplo 1.

Exemplo 1

Considere um servidor de *video-streaming* com uma interface de rede de 10 Mbps e com todos os filmes do seu catálogo disponíveis em formato standard (2.0 Mbps) e HD (4.0 Mbps).

No período de maior tráfego, a taxa de pedidos de filmes é de 2 pedidos/hora de filmes em formato standard e 1 pedido/hora de filmes em formato HD. Os filmes têm uma duração exponencialmente distribuída de média 90 minutos.

Quando um filme é pedido, ele começa a ser transmitido se houver capacidade disponível na interface de rede ou é recusado caso contrário.

Taxas de transição:

$\lambda_1 = 2 \text{ horas}^{-1}$ (taxa de chegada para o formato standard)

$\lambda_2 = 1 \text{ horas}^{-1}$ (taxa de chegada para o formato HD)

$1/\mu = 90 \text{ min} = 3/2 \text{ horas}$ (igual para os 2 formatos)

$\mu_1 = \mu_2 = 2/3 \text{ horas}^{-1}$ (taxa de partida de cada filme)

Cadeia de Markov do Exemplo 1 (Diagrama de Transição de Estados)

Estados:



i - nº de filmes em formato standard em transmissão

j - nº de filmes em formato HD em transmissão

$B_{ij} \rightarrow 2 \times i + 4 \times j$ capacidade da ligação ocupada pelo estado ij


Taxas de transição:

$$\lambda_1 = 2 \text{ horas}^{-1}$$


$$\lambda_2 = 1 \text{ horas}^{-1}$$

$$\mu_1 = 2/3 \text{ horas}^{-1}$$


$$\mu_2 = 2/3 \text{ horas}^{-1}$$



Exemplo 1 – resolução matricial no MATLAB



Exemplo 1 – resolução no MATLAB



```
>> u=M\x
```

```
u =
```

```
0.0236
0.0708
0.1061
0.1061
0.0796
0.0478
0.0354
0.1061
0.1592
0.1592
0.0265
0.0796
```

Bloqueio dos filmes em
formato standard

```
>> p_st= u(6)+u(10)+u(12)
```

```
p_st =
0.2866
```

```
>> p_hd= u(5)+u(6)+u(9)+u(10)+u(11)+u(12)
```

```
p_hd =
0.5519
```

Bloqueio dos filmes em
formato HD

Desempenho de um servidor de *video-streaming*

- No caso geral, a cadeia de Markov pode tornar-se demasiado grande:
 - No exemplo anterior (Exemplo 1), se a capacidade de ligação for $C = 1$ Gbps (em vez de 10 Mbps), o número de estados sobe de 12 para aproximadamente 6300
 - No caso geral, é ainda pior pois o número de formatos possíveis é maior (cada um adequado para diferentes tipos de terminais)
 - HD (High Definition): imagem de 1280 x 720 pixels (< 1 megapixel)
 - FHD (Full HD): imagem de 1920 x 1080 píxeis (2.07 megapíxeis)
 - UHD (Ultra HD): imagem de 3840 x 2160 píxeis (8.29 megapíxeis)
 - 4K: resolução de imagem de 4096 x 2160 píxeis (8.85 megapíxeis)
 - O formato pedido é tipicamente o que mais se adequa ao terminal em uso (smartphone, tablet, smart TV, etc...)
- Para podermos estimar o desempenho destes casos, é necessário considerar uma aproximação.

Desempenho de um servidor de *video-streaming*

- Uma aproximação possível para lidar com o caso geral é:
 - considerar um único formato com o débito binário médio dos filmes, usando a probabilidade de pedido de cada formato;
 - usar o sistema $M/M/m/m$ assumindo o formato único.

- Se cada filme estiver disponível em F formatos, em que a cada formato i (com $i = 1, 2, \dots, F$) está associado:
 - uma taxa de pedidos de filmes de λ_i
 - um débito binário de B_i
- Então o servidor pode ser modelado por um $M/M/m/m$ em que a taxa de chegada de pedidos é:

$$\lambda = \sum_{i=1}^F \lambda_i$$

e o débito binário de cada filme é:

$$B = \frac{\sum_{i=1}^F \lambda_i B_i}{\sum_{i=1}^F \lambda_i}$$

Exemplo 2

Considere um servidor de *video-streaming* com uma interface de rede de 100 Mbps e com todos os filmes disponíveis em formato standard (2.0 Mbps) e HD (4.0 Mbps).

A taxa de pedidos de filmes é de λ_1 pedidos/hora (filmes em formato standard) e λ_2 pedidos/hora (filmes em formato HD). Os filmes têm uma duração exponencialmente distribuída de média 90 minutos.

PB1: probabilidade de bloqueio de filmes em formato standard


PB2: probabilidade de bloqueio de filmes em formato HD

PBa: probabilidade de bloqueio do servidor no método aproximado

λ_1	λ_2	PB1	PB2	PBa
6	4	0.0006%	0.0016%	0.0004%
5	5	0.0029%	0.0074%	0.0023%
4	6	0.0101%	0.0254%	0.0107%
3	7	0.0283%	0.0692%	0.0442%

Serviços de dados

- Os serviços de dados são o tipo de serviço mais comum, tais o acesso a sites baseados em servidores Web
- Um caso extremo é o acesso a LLMs (por exemplo, ChatGPT, Claude, Gemini), que providenciam respostas a pedidos (em forma de um prompt)
- Nestes casos, a determinação de cada resposta é dependente da capacidade de processamento do servidor (quanto maior a capacidade de processamento, mais rápida é a resposta) e o débito binário de transmissão de cada resposta não é significativo
- Assim, a capacidade de processamento é muito mais limitativa que a capacidade da ligação



Desempenho de um servidor de um serviço de dados

- Em serviços de dados, o desempenho do servidor é limitado pela sua capacidade de processamento.
- Por exemplo, um servidor Web pode receber milhares de pedidos HTTP por dia cujo tempo de resposta por pedido pode tornar-se demasiado grande se o número de pedidos em processamento ultrapassar a capacidade do servidor.
- Para evitar esta situação:
 - através de testes de stress, é primeiro determinado um número máximo m de pedidos que podem estar simultaneamente em processamento e que permitam um tempo de resposta por pedido aceitável,
 - o servidor é então configurado para recusar os pedidos que chegam quando ele está a processar m pedidos em simultâneo.
- O servidor serve os pedidos à sua capacidade máxima e dividindo igualmente os seus recursos de processamento pelos pedidos atuais:
 - Disciplina *PS* (*Processor Sharing*): cada pedido recebe uma pequena quantidade de serviço que é suspenso até que todos os outros pedidos recebam a mesma quantidade de serviço


Desempenho de um servidor de um serviço de dados

- Este sistema pode ser modelado por um sistema $M/M/1/m^*PS$:
 - (1) a chegada de clientes é um processo de Poisson com taxa λ
 - (2) o sistema tem 1 servidor
 - (3) o servidor atende até m clientes
 - (4) o sistema tem capacidade de m clientes (i.e., não tem fila de espera)
 - (5) o servidor atende os clientes com um tempo exponencialmente distribuído por cliente de $n/m\mu$ em que n é o número de clientes no sistema
- Na notação $M/M/1/m^*PS$, o termo ' m^*PS ' significa que o servidor pode aceitar até m clientes e atende os clientes segundo uma disciplina *Processor Sharing*.
- A característica (5) significa que o tempo de atendimento é tanto maior quanto maior for o número de clientes no sistema

Sistema $M/M/m/m$

Sistema $M/M/m/m$:

- existem m servidores,
- cada servidor atende um cliente à taxa μ
- no estado n , ($n = 1, \dots, m$), os n clientes são atendidos à taxa $n\mu$




VS.


sistema $M/M/1/m^*PS$

Sistema $M/M/1/m^*PS$:

- existe 1 servidor com capacidade de m clientes,
- o servidor atende clientes à taxa $m\mu$
- no estado n , ($n = 1, \dots, m$), os n clientes são atendidos à taxa $m\mu/n$



Sistema $M/M/1/m^*PS$



Probabilidade de n clientes no sistema em estado estacionário:

$$\pi_n = \frac{\left(\frac{\lambda}{m\mu}\right)^n}{\sum_{i=0}^m \left(\frac{\lambda}{m\mu}\right)^i}, \quad n = 0, 1, 2, \dots, m$$

Ou por manipulação algébrica:

$$\pi_n = \frac{(1 - \rho)}{(1 - \rho^{m+1})} \times \rho^n, \quad n = 0, 1, 2, \dots, m$$

Se $\frac{\lambda}{m\mu} < 1$ e considerando $\rho = \frac{\lambda}{m\mu}$

Pela propriedade PASTA, a probabilidade de um cliente chegar e encontrar o sistema cheio é igual à probabilidade do estado m :

$$\pi_m = \frac{\left(\frac{\lambda}{m\mu}\right)^m}{\sum_{i=0}^m \left(\frac{\lambda}{m\mu}\right)^i} \quad \text{ou} \quad \pi_m = \frac{(1 - \rho)}{(1 - \rho^{m+1})} \times \rho^m$$

Exemplo 3

Considere um servidor de dados com uma capacidade para atender até 4 pedidos de serviço e que na sua capacidade máxima atende cada pedido com um tempo de serviço exponencialmente distribuído de média 2 milissegundos. Quando os pedidos de serviço chegam a uma taxa de 800 pedidos/segundo, queremos saber:

a) a probabilidade de bloqueio do servidor

$$\lambda = 800 \text{ pedidos/seg}$$

$$1/\mu = 2 \times 10^{-3} \text{ seg}$$

$$\mu = 500 \text{ pedidos/seg}$$

$$\rho = \frac{\lambda}{m\mu} = \frac{800}{4 \times 500} = 0.4$$

$$\pi_4 = \frac{(1-0.4)}{(1-0.4^5)} \times 0.4^4 = 0.0155$$

$$\pi_n = \frac{(1 - \rho)}{(1 - \rho^{m+1})} \times \rho^n, n = 0, 1, 2, \dots, m$$

R: a probabilidade de bloqueio é 1.55%

Exemplo 3

Considere um servidor de dados com uma capacidade para atender até 4 pedidos de serviço e que na sua capacidade máxima atende cada pedido com um tempo de serviço exponencialmente distribuído de média 2 milissegundos. Quando os pedidos de serviço chegam a uma taxa de 800 pedidos/segundo, queremos saber:

b) o número médio de pedidos em processamento do servidor

$$\lambda = 800 \text{ pedidos/seg}$$

$$1/\mu = 2 \times 10^{-3} \text{ seg}$$

$$\mu = 500 \text{ pedidos/seg}$$

$$\rho = \frac{\lambda}{m\mu} = \frac{800}{10 \times 500} = 0.4$$

$$L = \sum_{n=0}^4 n \times \pi_n = \frac{(1 - \rho)}{(1 - \rho^5)} (\rho + 2\rho^2 + 3\rho^3 + 4\rho^4)$$

$$= \frac{(1 - 0.4)}{(1 - 0.4^5)} (0.4 + 2 \times 0.4^2 + 3 \times 0.4^3 + 4 \times 0.4^4) = 0.6149$$

$$\pi_n = \frac{(1 - \rho)}{(1 - \rho^{m+1})} \times \rho^n, n = 0, 1, 2, \dots, m$$

R: o número médio de pedidos em processamento é 0.6149

Exemplo 3

Considere um servidor de dados com uma capacidade para atender até 4 pedidos de serviço e que na sua capacidade máxima atende cada pedido com um tempo de serviço exponencialmente distribuído de média 2 milissegundos. Quando os pedidos de serviço chegam a uma taxa de 800 pedidos/segundo, queremos saber:

c) o tempo médio de serviço de cada pedido

$$\lambda = 800 \text{ pedidos/seg}$$

$$1/\mu = 2 \times 10^{-3} \text{ seg}$$

$$\mu = 500 \text{ pedidos/seg}$$

$$\rho = \frac{\lambda}{m\mu} = \frac{800}{10 \times 500} = 0.4$$

$$W = \frac{L}{\lambda(1 - \pi_4)}$$

Teorema de Little

Resultado de b)

$$W = \frac{0.6149}{800 \times (1 - 0.0155)} = 7.81 \times 10^{-4} \text{ seg.}$$

Resultado de a)


R: o tempo médio de serviço é 0.781 mseg. (NOTA: 2 mseg. é o tempo de serviço quando o servidor está a atender 4 clientes em simultâneo)

Desempenho de um servidor de um serviço do tipo *Call Center*

- Em serviços de tipo *Call Center*:
 - existe um conjunto de m operadores disponíveis para atender clientes
 - quando um pedido de um cliente chega, o pedido:
 - é atribuído a um operador disponível ou
 - é posto em fila de espera se os m operadores estiverem ocupados
 - quando um operador fica disponível, é-lhe imediatamente atribuído o pedido em espera mais antigo (i.e., os pedidos em espera são atendidos por ordem de chegada)
 - o tempo de serviço é caracterizado pelo tempo de atendimento de um operador a um cliente
- O desempenho do serviço pode ser modelado por um sistema $M/M/m$.


Sistema $M/M/m$

- Processo de nascimento e morte em que:
 - (1) a chegada de clientes é um processo de Poisson com taxa λ
 - (2) o sistema tem m servidores
 - (3) cada servidor atende um cliente de cada vez com um tempo exponencialmente distribuído de média $1/\mu$
 - (4) o sistema acomoda um número infinito de clientes



- Nos estados $n = 0, 1, \dots, m$, o sistema tem n clientes em atendimento e 0 clientes em espera.
- Nos estados $n = m+1, m+2, \dots, m+i$, o sistema tem m clientes em atendimento e i clientes em espera.

Sistema $M/M/m$ (probabilidades limite)



Probabilidades limite
de um processo de
nascimento e morte

$$\pi_0 = \frac{1}{1 + \sum_{k=1}^{\infty} \left(\frac{\lambda_0 \lambda_1 \dots \lambda_{k-1}}{\mu_1 \mu_2 \dots \mu_k} \right)}$$

$$\pi_n = \frac{\lambda_0 \lambda_1 \dots \lambda_{n-1}}{\mu_1 \mu_2 \dots \mu_n} \pi_0$$


$M/M/m$:

Considerando $\rho = \frac{\lambda}{m\mu}$

$$\pi_0 = \frac{1}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!} \right) + \frac{(m\rho)^m}{m! (1 - \rho)}} \quad \pi_n = \begin{cases} \frac{\frac{(m\rho)^n}{n!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!} \right) + \frac{(m\rho)^m}{m! (1 - \rho)}} & , n \leq m \\ \frac{\frac{m^m \rho^n}{m!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!} \right) + \frac{(m\rho)^m}{m! (1 - \rho)}} & , n > m \end{cases}$$

Condição de validade: $\rho = \frac{\lambda}{m\mu} < 1$

M/M/m (alguns parâmetros de desempenho)



Probabilidades limite
do M/M/m

$$\rho = \frac{\lambda}{m\mu}$$

$$\pi_0 = \frac{1}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!(1-\rho)}}$$

$$\pi_n = \begin{cases} \frac{\frac{(m\rho)^n}{n!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!(1-\rho)}}, & n \leq m \\ \frac{\frac{m^m \rho^n}{m!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!(1-\rho)}}, & n > m \end{cases}$$

Probabilidade de todos os
servidores estarem ocupados

$$P_Q = \sum_{n=m}^{+\infty} \pi_n = \frac{(m\rho)^m}{m!(1-\rho)} \pi_0$$

No. médio de clientes
na fila de espera

$$L_Q = \sum_{n=m+1}^{+\infty} (n-m) \times \pi_n = \frac{\rho}{(1-\rho)} P_Q$$

Atraso médio de clientes
na fila de espera

$$W_Q = \frac{L_Q}{\lambda} = \frac{\rho}{\lambda(1-\rho)} P_Q$$

Exemplo 4

Um servidor de *Call Center* tem 4 operadores e prevê uma taxa de chegada de 60 pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média. Queremos saber:

a) a probabilidade de um pedido ser imediatamente atendido

$$\lambda = 60/60 = 1 \text{ pedidos/min}$$

$$1/\mu = 3 \text{ min}$$

$$\mu = 1/3 \text{ pedidos/min}$$

$$\rho = \frac{\lambda}{m\mu} = \frac{1}{4 \times 1/3} = 0.75$$

$$\pi_0 = \frac{1}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!(1-\rho)}}$$

$$P_Q = \frac{(m\rho)^m}{m!(1-\rho)} \pi_0 \quad \rho = \frac{\lambda}{m\mu}$$

$$\pi_0 = \frac{1}{1 + \frac{4 \times 0.75}{1!} + \frac{(4 \times 0.75)^2}{2!} + \frac{(4 \times 0.75)^3}{3!} + \frac{(4 \times 0.75)^4}{4! \times (1 - 0.75)}} = 0.037736$$

$$P_Q = \frac{(4 \times 0.75)^4}{4! \times (1 - 0.75)} \times 0.037736 = 0.5094$$

R: Um pedido é imediatamente atendido com probabilidade $1 - P_Q$ ou seja com probabilidade 49.06%

Exemplo 4

Um servidor de *Call Center* tem 4 operadores e prevê uma taxa de chegada de 60 pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média. Queremos saber:

b) o tempo médio que os clientes esperam na fila de espera

$$\lambda = 60/60 = 1 \text{ pedidos/min}$$

$$1/\mu = 3 \text{ min}$$

$$\mu = 1/3 \text{ pedidos/min}$$

$$\rho = \frac{\lambda}{m\mu} = \frac{1}{4 \times 1/3} = 0.75$$

$$W_Q = \frac{\rho}{\lambda(1 - \rho)} P_Q \quad \rho = \frac{\lambda}{m\mu}$$

$$W_Q = \frac{0.75}{1 \times (1 - 0.75)} \times 0.5094 = 1.5282$$

R: Cada cliente está em média 1.53 minutos em espera até começar a ser atendido

Exemplo 4

Um servidor de *Call Center* tem 4 operadores e prevê uma taxa de chegada de 60 pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média. Queremos saber:

c) o número médio de operadores ocupados

$$\lambda = 60/60 = 1 \text{ pedidos/min}$$

$$1/\mu = 3 \text{ min}$$

$$\mu = 1/3 \text{ pedidos/min}$$

$$\rho = \frac{\lambda}{m\mu} = \frac{1}{4 \times 1/3} = 0.75$$

$$\pi_n = \frac{\frac{(m\rho)^n}{n!}}{\left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!}\right) + \frac{(m\rho)^m}{m!(1-\rho)}}, n \leq m$$

calculado em 4a)

$$N_O = 0\pi_0 + 1\pi_1 + 2\pi_2 + 3\pi_3 + 4 \mathbf{P_Q}$$

$$N_O = \frac{\frac{4 \times 0.75}{1!} + 2 \times \frac{(4 \times 0.75)^2}{2!} + 3 \times \frac{(4 \times 0.75)^3}{3!}}{1 + \frac{4 \times 0.75}{1!} + \frac{(4 \times 0.75)^2}{2!} + \frac{(4 \times 0.75)^3}{3!} + \frac{(4 \times 0.75)^4}{4! \times (1 - 0.75)}} + 4 \times 0.5094$$

$$N_O = 3.0$$

R: Em média, estão 3.0 operadores ocupados

Exemplo 5

Um servidor de *Call Center* tem m operadores e prevê uma taxa de chegada de λ pedidos por hora. Cada chamada tem uma duração exponencial de 3 minutos de média.

P_Q : probabilidade de todos os operadores estarem ocupados

W_Q : tempo médio dos clientes em espera

λ (hora ⁻¹)	m	P_Q	W_Q (seg.)
750	50	3.41%	0.49
800	50	8.70%	1.57
850	50	18.97%	4.55
900	50	36.39%	13.10
950	50	62.91%	45.29
1500	100	0.37%	0.03
1600	100	1.97%	0.18
1700	100	7.49%	0.90
1800	100	21.69%	3.90
1900	100	50.64%	18.23

Tipos de serviços mistos

- Exemplo: serviços de música online (Spotify, Apple Music, YouTube Music, etc.) que permitem ouvir e partilhar músicas online
- O tempo de serviço é caracterizado pela duração da sessão do utilizador (i.e., desde que ele se liga até que se desliga do serviço)
- Durante cada sessão, há a transmissão de um débito binário variável (envio das sucessivas músicas e tempos entre músicas)
- Como o débito binário da música é muito menor que dos filmes, a capacidade da ligação e a capacidade de processamento podem ser ambas limitativas
- O desempenho do serviço pode ser modelado por um sistema $M/M/m/m$ em que m é escolhido como o menor entre o número máximo de sessões permitido:

- pela capacidade de processamento do servidor
- pela capacidade C da ligação de rede do servidor

